

OPC Data Analyst Projet

Synthèse de projet

Arnaud Golliot
7 Août 2024



Sommaire

- 1. Normalisation du modèle de données**
- 2. Étapes du projet**
- 3. Dictionnaires des données (avant et après normalisation)**
- 4. Schéma relationnel normalisé**
- 5. Structure et contenu des tables**
- 6. Résultat et code des requêtes SQL**



Normalisation du modèle de données



Normalisation du modèle de données

Constat :

Les deux fichiers CSV fournis – Contrats.csv et Régions.csv - contiennent de nombreuses redondances de données, ce qui présente les écueils suivants :

- ✓ **La volumétrie** : plus les mêmes valeurs de données sont répétées, plus la base de données résultant du chargement de ces deux fichiers sera gourmande en espace de stockage
- ✓ **La lisibilité** : les deux fichiers contiennent plusieurs concepts, ce qui en pénalise la compréhension
 - Contrats.csv : il adresse deux concepts, les contrats mais aussi les logements
 - Régions.csv : il adresse trois concepts différents
- ✓ **La consistance** : modifier un valeur de donnée en base nécessiterait d'en ressaisir la valeur à tous les endroits où elle se trouve, ce qui est chronophage et surtout présente un risque, pour ne pas dire certitude, d'avoir des valeurs de données différentes pour un même concept (par exemple plusieurs adresses différentes pour un même logement, typiquement « 1, rue Jean Jaurès » et « 1 rue J.Jaurès))

Solutions :

Afin de pallier à ces écueils, nous avons transformé le modèle de données de manière à avoir 4 entités au lieu de deux. Cette transformation implique de découper les deux fichiers csv fournis en quatre fichiers cible. Le modèle de données résultant est dit en 3^{ème} forme normale (3FN). Dans ce type de modèle, chaque combinaison de données dans une entité est unique.



Étapes du projet



Normalisation du modèle de données

- 1) Etablissement du dictionnaire initial (2 entités : Contrat et Région)**
- 2) Etablissement du dictionnaire en 3ieme forme normale (5 entités : Contrat, Logement, Commune, Département et Région)**
- 3) Découpage des 2 fichiers CSV initiaux (Contrats.csv, Régions.csv) en 5 fichiers CSV normalisés (Contrats.csv, Logements.csv, Communes.csv, Departements.csv, Regions.csv). Neutralisation des doublons. Rajout de clés primaires. Rajout de données manquantes (communes de la réunion)**
- 4) Installation du SGBD MYSQL**
- 5) Ecriture avec SUBLIME TEXT et exécution avec MYSQL COMMAND LINE du script SQL de création de la base de données**
- 6) Ecriture avec SUBLIME TEXT et exécution avec MYSQL COMMAND LINE du script SQL de création et d'alimentation des tables**
- 7) Vérification du contenu et du nombre d'enregistrements des tables dans MYSQL Workbench**
- 8) Ecriture des 12 requêtes SQL (plus requête de test) avec l'éditeur SUBLIME TEXT, et exécution dans MYSQL Workbench**



Dictionnaires de données

Dictionnaire de données initial

CONTRAT CSV

Nom des colonnes	Type de données	Taille	Clé	Description
Contrat_ID	INT		Clé primaire	Id unique pour les contrats
No_voie	CVARCHAR	3		Numéro dans la voie pour l'adresse du logement assuré Le numéro de voie n'est pas fondamentalement une variable quantitative, mieux vaut la mettre en type CVARCHAR
B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
Type_de_voie	CVARCHAR	4		Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
Voie	CVARCHAR	30		Libellé de la voie pour l'adresse du logement assuré
Code_dep_code_commune	CVARCHAR	6	Clé secondaire	Concaténation du code département et code commune pour avoir une clé unique Attention : les deux codes de la Corse contiennent des caractères (2A, 2B)
Code_postal	CVARCHAR	5		Code postal pour l'adresse du logement assuré Attention : le code postal n'est pas une donnée quantitative, mieux vaut le mettre en type CVARCHAR
Surface	INT			Surface du logement assuré
Type_local	CVARCHAR	20		Type de logement (maison, appartement)
Occupation	CVARCHAR	20		Qualité de l'occupant (propriétaire, locataire)
Type_contrat	CVARCHAR	30		Type de contrat de la personne assurée (résidence principale, résidence secondaire, mise en location)
Formule	CVARCHAR	20		Formule du contrat d'assurance (Classique, Integral)
Valeur_declaree_biens	CVARCHAR	20		Tranche de valeur des biens déclarés par l'assuré (4 tranches : 0-25K€, 25-50K€, 50-100K€, > 100K€)
Prix_cotisation_mensuelle	INT			Prix de la cotisation mensuelle de l'assurance contractée par l'assuré

REGION CSV

Nom des colonnes	Type de données	Taille	Clé	Description
Code_dep_code_commune	CVARCHAR	6	Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
reg_code	INT			Code région (par exemple : 44 pour la région Grand Est)
reg_nom	CVARCHAR	30		Nom de la région
aca_nom	CVARCHAR	40		Nom de l'académie (exemple : académie de Versailles)
dep_nom	CVARCHAR	50		Nom du département
com_nom_maj_court	CVARCHAR	50		Nom de la commune en majuscules (exemple : AMBERIEU EN BUGEY)
dep_code	INT	3		Code département (de 01 à 98)
dep_nom_num	VACHAR	50		Nom du département complété en suffixe par le code département entre parenthèses)

Dictionnaire de données normalisé (3FN)

Entité : Contrat

Nom des colonnes	Type de donnée	Taille	Clé	Description
Id_contrat	INT		Clé primaire	Id unique pour les contrats
Type_contrat	CVARCHAR	30		Type de contrat de la personne assurée (résidence principale, résidence secondaire, mise en location)
Formule	CVARCHAR	20		Formule du contrat d'assurance (Classique, Integral)
Valeur_declaree_biens	CVARCHAR	20		Tranche de valeur des biens déclarés par l'assuré (4 tranches : 0-25K€, 25-50K€, 50-100K€, > 100K€)
Prix_cotisation_mensuelle	INT			Prix de la cotisation mensuelle de l'assurance contractée par l'assuré
Code_logement	INT		Clé secondaire	Identifiant unique de logement

Entité : Commune

Nom des colonnes	Type de donnée	Taille	Clé	Description
Code_commune	INT		Clé primaire	Identifiant de commune
Code_postal	CVARCHAR	7		Code postal pour l'adresse du logement assuré Attention : le code postal n'est pas une donnée
Nom_commune	CVARCHAR	50		Nom de la commune en majuscules (exemple : AMBERIEU EN BUGEY)
Code_departement	INT	3	Clé secondaire	Code département (de 01 à 98)

Entité : Logement

Nom des colonnes	Type de donnée	Taille	Clé	Description
Code_logement	INT		Clé primaire	Identifiant unique de logement
No_voie	CVARCHAR	3		Numéro dans la voie pour l'adresse du logement assuré
B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
Type_de_voie	CVARCHAR	4		Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
Voie	CVARCHAR	30		Libellé de la voie pour l'adresse du logement assuré
Code_commune	INT		Clé secondaire	Identifiant unique de commune
Surface	INT			Surface du logement assuré
Type_local	CVARCHAR	20		Type de logement (maison, appartement)
Occupation	CVARCHAR	20		Qualité de l'occupant (propriétaire, locataire)

Entité : Département

Nom des colonnes	Type de donnée	Taille	Clé	Description
Code_departement	INT	3	Clé primaire	Code département (de 01 à 98)
Nom_departement	CVARCHAR	50		Nom du département
Code_region	INT		Clé secondaire	Code région

Entité : Région


Nom des colonnes	Type de donnée	Taille	Clé	Description
Code_region	INT		Clé primaire	Code région (par exemple : 44 pour la région Grand Est)
reg_nom	CVARCHAR	30		Nom de la région



Schéma relationnel normalisé (3FN)

Schéma relationnel

Modèle en 3FN





Structure et contenu des tables dans la BDD

Structure et contenu des tables dans la BDD

Table: contrat

Columns:

id_contrat	int PK
type_contrat	varchar(30)
formule	varchar(20)
valeur_declaree_bien	varchar(20)
prix_cotisation_mensuelle	int
id_logement	int

	id_contrat	type_contrat	formule	valeur_declaree_bien	prix_cotisation_mensuelle	id_logement
▶	100601	Residence principale	Integral	0-25000	25	147
	100602	Residence principale	Classique	0-25000	30	50
	100603	Residence principale	Integral	25000-50000	57	63
	100604	Residence principale	Integral	25000-50000	43	131
	100605	Residence principale	Classique	0-25000	33	16
	100606	Residence principale	Classique	0-25000	19	149
	100607	Residence principale	Integral	0-25000	15	160
	100608	Mise en location	Integral	25000-50000	34	67
	100609	Residence principale	Classique	25000-50000	32	151
	100610	Residence principale	Integral	25000-50000	22	132
	100611	Residence secondaire	Classique	0-25000	11	130
	100612	Residence principale	Classique	0-25000	16	90

30335 row(s) returned

Table: logement

Columns:

id_logement	int PK
num_voie	varchar(4)
b_t_q	varchar(1)
type_voie	varchar(4)
voie	varchar(30)
surface	int
type_local	varchar(20)
occupation	varchar(20)
code_commune	int

	id_logement	num_voie	b_t_q	type_voie	voie	surface	type_local	occupation	code_commune
▶	1	59		RUE	ALEXANDRE BERARD	165	Appartement	Locataire	2
	2	54	B	RUE	ARISTIDE BRIAND	70	Appartement	Locataire	2
	3	2		RUE	DE LA BATISSE	81	Appartement	Proprietaire	2
	4	25		RUE	DE LA COMMUNE 1871	70	Maison	Proprietaire	2
	5	72		RUE	DE LA REPUBLIQUE	36	Appartement	Proprietaire	2
	6	36		RUE	DES APOTRES	75	Appartement	Locataire	2
	7	60		ALL	DES FRERES CAUDRON	51	Appartement	Proprietaire	2
	8	78		AV	DU GEN SARRAIL	92	Appartement	Proprietaire	2
	9	13		RUE	JEAN MONNET	55	Appartement	Proprietaire	2
	10	54		RUE	MARCEL DEMIA	68	Appartement	Locataire	2
	11	29		RUE	REINE CLOTILDE	55	Appartement	Proprietaire	2
	12	47		RUE	DU CHANE	48	Appartement	Proprietaire	12

30083 row(s) returned

Structure et contenu des tables dans la BDD

Table: **commune**

Columns:

code_commune int PK
code_postal varchar(20)
nom_commune varchar(50)
code_dep varchar(3)

	code_commune	code_postal	nom_commune	code_dep
▶	1	Non référencé	AMAREINS	1
	2	1004	AMBERIEU EN BUGEY	1
	3	Non référencé	AMBERIEUX EN DOMBES	1
	4	Non référencé	AMBLEON	1
	5	Non référencé	AMBRONAY	1
	6	Non référencé	AMBUTRIX	1
	7	Non référencé	ANDERT ET CONDON	1
	8	Non référencé	ANGLEFORT	1

38917 row(s) returned

Table: **departement**

Columns:

code_dep varchar(3) PK
nom_dep varchar(50)
code_reg int

	code_dep	nom_dep	code_reg
▶	1	Ain	84
	10	Aube	44
	11	Aude	76
	12	Aveyron	76
	13	Bouches-du-Rhône	93
	14	Calvados	28
	15	Cantal	84
	16	Charente	75
	17	Charente-Maritime	75

109 row(s) returned

Table: **region**

Columns:

code_reg int PK
nom_reg varchar(30)

	code_reg	nom_reg
▶	0	Collectivités d'outre-mer
	1	Guadeloupe
	2	Martinique
	3	Guyane
	4	La Réunion
	6	Mayotte
	11	Ile-de-France
	24	Centre-Val de Loire

19 row(s) returned



Code SQL et résultat des requêtes

Résultat et code des requêtes SQL

Requête exemple : Lister les contrats avec le prix de la cotisation et leur surface pour les appartements

```
SELECT CTR.id_contrat, CTR.prix_cotisation_mensuelle, LOG.surface  
FROM contrat CTR  
LEFT OUTER JOIN logement LOG ON CTR.id_logement = LOG.id_logement  
WHERE LOG.type_local = 'Appartement';
```

	id_contrat	prix_cotisation_mensuelle	surface
▶	100601	25	50
	100602	30	48
	100603	57	131
	100605	33	109
	100606	19	53
	100607	15	59
	100610	22	36
	100611	11	138
	100612	16	45
	100613	14	83
	100614	34	88

27837 row(s) returned

Requête n°1 : Lister les numéros de contrats (id_contrat) avec leur surface pour la commune de Caen.

```
SELECT CTR.id_contrat,  
LOG.surface  
FROM contrat CTR  
LEFT OUTER JOIN logement LOG ON CTR.id_logement = LOG.id_logement  
LEFT OUTER JOIN commune COM ON LOG.code_commune = COM.code_commune  
WHERE COM.nom_commune = 'CAEN';
```

	id_contrat	surface
▶	103791	35
	103792	99
	103793	40
	103794	20

4 row(s) returned

Résultat et code des requêtes SQL

Requête n°2 : Lister les numéros de contrats avec le type de contrat et leur formule pour les maisons du département 71.

```
SELECT CTR.id_contrat, CTR.type_contrat, CTR.formule  
FROM contrat CTR  
LEFT OUTER JOIN logement LOG ON CTR.id_logement = LOG.id_logement  
LEFT OUTER JOIN commune COM ON LOG.code_communne = COM.code_communne  
LEFT OUTER JOIN departement DEP ON COM.code_dep = DEP.code_dep  
WHERE LOG.type_local = 'Maison'  
AND DEP.code_dep = '71'  
ORDER BY CTR.id_contrat ASC
```

	contrat_id	type_contrat	formule
▶	114768	Residence principale	Integral
	114779	Residence principale	Classique
	114782	Residence principale	Classique
	114812	Residence principale	Integral

4 row(s) returned

Requête n°3 : Lister le nom des régions de France.

```
SELECT REG.nom_reg  
FROM region REG  
ORDER BY REG.nom_reg;
```

nom_reg
Auvergne-Rhône-Alpes
Bourgogne-Franche-Comté
Bretagne
Centre-Val de Loire
Collectivités d'outre-mer
Corse
Grand Est
Guadeloupe
Guyane
Hauts-de-France
Ile-de-France
La Réunion
Martinique
Mayotte
Normandie
Nouvelle-Aquitaine
Occitanie
Pays de la Loire
Provence-Alpes-Côte d'Azur

19 row(s) returned

Résultat et code des requêtes SQL

Requête n°4 : Quels sont les 5 contrats qui ont les surfaces les plus élevées ?

```
SELECT CTR.id_contrat, LOG.surface  
FROM contrat CTR  
LEFT OUTER JOIN logement LOG ON CTR.id_logement = LOG.id_logement  
ORDER BY LOG.surface DESC  
LIMIT 5;
```

	id_contrat	surface
▶	104211	815
	105463	742
	130878	595
	100822	570
	109872	559
*	NULL	NULL

5 row(s) returned

Requête n°5 : Quel est le prix moyen de la cotisation mensuelle ?

```
SELECT CONCAT(ROUND(AVG(CTR.prix_cotisation_mensuelle), 2), ' €') AS 'Moyenne cotisation Mensuelle'  
FROM contrat CTR;
```

Moyenne cotisation Mensuelle
▶ 19.33 €

1 row(s) returned

Requête n°6 : Quel est le nombre de contrats pour chaque catégorie de prix de la valeur déclarée des biens ?

```
SELECT CTR.valeur_declaree_bien AS 'Catégorie de biens',  
COUNT(CTR.id_contrat) AS 'Nombre de contrats'  
FROM contrat CTR  
GROUP BY CTR.valeur_declaree_bien  
ORDER BY COUNT(CTR.id_contrat) DESC;
```

Catégorie de biens	Nombre de contrats
▶ 0-25000	22720
25000-50000	6815
50000-100000	696
100000+	104

4 row(s) returned

Résultat et code des requêtes SQL

Requête n°7 : Quel est le nombre de formules "integral" sur la région Pays de la Loire ?

```
SELECT COUNT(CTR.id_contrat) AS 'Nombre de contrat en formule Intégrale pour les Pays de la Loire'  
FROM contrat CTR  
LEFT OUTER JOIN logement LOG ON CTR.id_logement = LOG.id_logement  
LEFT OUTER JOIN commune COM ON LOG.code_commune = COM.code_commune  
LEFT OUTER JOIN département DEP ON COM.code_dep = DEP.code_dep  
LEFT OUTER JOIN région REG ON DEP.code_req = REG.code_req  
WHERE REG.nom_req = 'Pays de la Loire'  
AND CTR.formule = 'Integral';
```

Nombre de contrat en formule Intégrale pour les Pays de la Loire	
▶	589
1 row(s) returned	

Requête n°8 : Lister les numéros de contrats avec le type de contrat et leur formule pour les maisons du département 71.

```
SELECT CTR.id_contrat, CTR.type_contrat, CTR.formule  
FROM contrat CTR  
LEFT OUTER JOIN logement LOG ON CTR.id_logement = LOG.id_logement  
LEFT OUTER JOIN commune COM ON LOG.code_commune = COM.code_commune  
LEFT OUTER JOIN département DEP ON COM.code_dep = DEP.code_dep  
WHERE LOG.type_local = 'Maison'  
AND DEP.code_dep = '71';  
ORDER BY CTR.id_contrat ASC
```

	id_contrat	type_contrat	formule
▶	114768	Residence principale	Integral
	114779	Residence principale	Classique
	114782	Residence principale	Classique
	114812	Residence principale	Integral

4 row(s) returned

Requête n°9 : Quelle est la surface moyenne des contrats à Paris ?

```
SELECT CONCAT(ROUND(AVG(LOG.surface), 2), ' M2')  
AS 'Surface moyenne des logements assurés à Paris'  
FROM contrat CTR  
LEFT OUTER JOIN logement LOG ON CTR.id_logement = LOG.id_logement  
LEFT OUTER JOIN commune COM ON LOG.code_commune = COM.code_commune  
LEFT OUTER JOIN département DEP ON COM.code_dep = DEP.code_dep  
WHERE DEP.nom_dep = 'Paris';
```

Surface moyenne des logements assurés à Paris	
▶	51.77 M2
1 row(s) returned	

Résultat et code des requêtes SQL

Requête n°10 : Classement des 10 départements où le prix moyen de la cotisation est le plus élevé

```
SELECT      DEP.nom_dep AS 'departement',
            CONCAT(ROUND(AVG(CTR.prix_cotisation_mensuelle),2), '€') AS 'cotisation_moyenne'
FROM        contrat CTR
LEFT OUTER JOIN logement LOG ON CTR.id_logement = LOG.id_logement
LEFT OUTER JOIN commune COM ON LOG.code_commune = COM.code_commune
LEFT OUTER JOIN departement DEP ON COM.code_dep = DEP.code_dep
GROUP BY    DEP.nom_dep
ORDER BY    AVG(CTR.prix_cotisation_mensuelle) DESC
LIMIT 10;
```

departement	cotisation_moyenne
Paris	36.40€
Hauts-de-Seine	26.27€
Val-de-Marne	19.82€
Yvelines	18.89€
Rhône	18.49€
Ain	18.24€
Alpes-Maritimes	18.14€
Charente-Maritime	17.32€
Haute-Savoie	17.15€
Corse-du-Sud	17.07€

10 row(s) returned

Requête n°11 : Liste des communes ayant eu au moins 150 contrats.

```
SELECT      COM.nom_commune AS 'Commune',
            COUNT(CTR.id_contrat) AS 'Nombre de contrats'
FROM        contrat CTR
LEFT OUTER JOIN logement LOG ON CTR.id_logement = LOG.id_logement
LEFT OUTER JOIN commune COM ON LOG.code_commune = COM.code_commune
GROUP BY    COM.code_commune
HAVING      COUNT(CTR.id_contrat) >= 150
ORDER BY    COUNT(CTR.id_contrat) DESC;
```

Commune	Nombre de contrats
PARIS 18	515
PARIS 17	468
PARIS 15	407
PARIS 16	394
NICE	387
PARIS 11	381
BORDEAUX	302
PARIS 20	302
NANTES	291
PARIS 19	266
PARIS 10	263
PARIS 12	252
PARIS 14	222
GRENOBLE	220
PARIS 9	204
TOULOUSE	187
TOULON	170
COURBEV...	163
LILLE	161
PARIS 3	159

20 row(s) returned

Résultat et code des requêtes SQL

Requête n°12 : Quel est le nombre de contrats pour chaque région ?

```
SELECT REG.nom_req AS 'Région',
       COUNT(CTR.id_contrat) AS 'Nombre de contrats'
  FROM contrat CTR
  LEFT OUTER JOIN logement LOG ON CTR.Id_llogement = LOG.id_llogement
  LEFT OUTER JOIN commune COM ON LOG.code_commune = COM.code_commune
  LEFT OUTER JOIN département DEP ON COM.code_dep = DEP.code_dep
  LEFT OUTER JOIN région REG ON DEP.code_req = REG.code_req
 GROUP BY REG.nom_req
 ORDER BY COUNT(CTR.id_contrat) DESC;
```

Région	Nombre de contrats
Île-de-France	14177
Provence-Alpes-Côte d'Azur	3279
Auvergne-Rhône-Alpes	3042
Nouvelle-Aquitaine	2038
Occitanie	1609
Pays de la Loire	1196
Hauts-de-France	1189
Bretagne	947
Normandie	824
Grand Est	769
Centre-Val de Loire	598
Bourgogne-Franche-Comté	293
Corse	247
Martinique	73
Guyane	37
La Réunion	17

16 row(s) returned